

國家科學及技術委員會補助
大專學生研究計畫研究成果報告

計 畫
： 結合AI整合技術與圖片辨識以提升詐騙辨識之精確度
名 稱

報 告 類 別 ： 成果報告
執行計畫學生： 黃予岑
學生計畫編號： NSTC 114-2813-C-030-031-E
研 究 期 間 ： 114年07月01日至115年02月28日止，計8個月
指 導 教 授 ： 廖建翔

處 理 方 式 ： 本計畫可公開查詢

執 行 單 位 ： 輔仁大學學校財團法人輔仁大學資訊管理學系（所）

中 華 民 國 115年02月10日

結合 AI 整合技術以提升詐騙辨識之精確度

摘要

在台灣，詐騙作為最常發生也最難預防的案件之一，儘管在新聞報導、政府宣傳及警方不斷地查獲和阻攔下，多數民眾的防詐意識皆有所提高，但在資訊傳播途徑日益多元的現代，詐騙集團的手法也逐漸滲透至日常資訊中，詐騙手法也不斷地推陳出新，諸如 Line 詐騙、購物詐騙、一頁式假網拍網站等等，導致被詐騙的件數及財損反而年年上升，詐騙件數也上升至 3 萬 7984 件，去年詐騙財損金額便高達 88 億元，案件數比 2022 年的 2.95 萬件增加 28.72%，財損金額也比 2022 年的 73 億餘元增加 21.17%。而詐騙種類 前三類分別為投資詐欺 1 萬 1719 件、占 30.85%、網路購物詐欺(含一般購物詐欺)8346 件、占 21.97%，及解除分期付款詐欺 6992 件、占 18.41%。

會造成上述現象的發生的原因之一，便是一般民眾在遭遇詐騙時無法精準地做出判斷。由於詐騙手法的演進，許多詐騙信息透過圖片或截圖的方式進行傳播，較文字更令民眾難以分辨真偽，便容易因為一時衝動而釀成難以挽回的過錯。為了應對這種因無法判斷而造成財物損失的情況，本研究的目的在於提升模型對詐騙風險的識別能力，不僅聚焦於圖片辨識，還結合網路爬蟲與自然語言處理技術，深入分析圖片與文字中的關鍵字與語意信息。其中，結合 AI 整合技術的範圍包含文字探勘與比對、圖片辨識、語意分析等。此外，本研究也將整合警政署詐騙案例資料與網路上的實際詐騙案例，進行 AI 整合技術比對，協助驗證其真偽。透過以上技術提高模型識別詐騙潛在風險的能力，從而提供更可靠的詐騙偵測結果，幫助使用者對於不管何種類型的詐騙都能輕鬆判斷以及應對，減少受到詐騙的可能性。

研究動機與研究問題

根據警政署「打詐儀錶板」的最新資料，光是今日(11 月 9 日)的詐騙受理數便有 556 件，財損數高達 2 億 7590 萬元，而下方圖表也顯示，今年 10 月全台遭詐騙 120 億 6844 萬元，比 9 月多了 1 億 9115 萬元；10 月的總受理詐騙數量也比 9 月多出 138 件，顯示不管是詐騙數量還是詐騙金額都在增長，是現今急需受到關注與解決的問題。

隨著科技的進步與社交媒體的普及，愈來愈多的詐騙案例轉向網路，採用一頁式網站或詐騙廣告等等。這些詐騙圖片通常包含引誘、偽造的標誌或文字，並可能將詐騙相關訊息（如聯絡方式、Line ID、銀行帳號等）巧妙地隱藏在圖片中，使其看似真實且較難以辨別。這種手法使得使用者在短時間內難以分辨真偽，進而增加受騙風險。傳統的詐騙偵測技術主要依賴於文字訊息的特徵提取，然而隨著詐騙方式的多元化，僅憑文字分析已不足以應對現今的詐騙風險。為了解決這一問題，本研究將著重於強化圖片辨識技術，以提高詐騙偵

測模型對圖片詐騙的識別能力，期望能提供準確度更高的防詐措施，幫助一般民眾在遇到詐騙時能作出即時、準確的判斷，進而減少財務損失的風險。

目前詐騙數不斷上升的一大原因便是，沒有一個足夠精準且廣為人知的整合型詐騙辨識技術，使得很多民眾難以第一時間察覺到自己遭到詐騙。會有這種現象的原因在於幾個方面的問題：

一、詐騙手法不斷演進且多樣化，詐騙者利用高科技手段製造出真假難辨的圖片、文字，讓民眾難以從直觀特徵中識別詐騙信息。特別是透過截圖或深度偽造的圖片，詐騙者能模擬真實場景，降低受害者的警覺性。二、現有技術在詐騙辨識上的侷限性。例如，文字檢測技術雖然能識別某些關鍵詞，但缺乏對語意層次的深度理解，因此在面對隱晦或誘導式的詐騙內容較難以辨識。同時，圖片辨識技術雖有所進步，但在低畫質、背景複雜或非標準化設計的詐騙圖片中，可能會因選擇工具的不同。難以達到高準確率，造成辨識上的誤差。三、現有的詐騙數據來源與範圍有限，數據集多半集中於已知的詐騙模式或案例，缺乏對新型詐騙手法的及時更新，導致模型的訓練資料漸漸無法滿足使用者需求，難以跟上快速變化的詐騙偵測需求。四、現今的詐騙手法常結合文字、圖片、網址等多種形式，容易造成辨識工作上更大的技術挑戰。現有技術在處理單一形式（如純文字或純圖片）時效果較佳，但面對多形式內容時，難以有效整合各種資訊來源，無法準確關聯不同形式之間的詐騙特徵，因此難以應對實際場景中的多樣化詐騙內容。

本研究透過整合自然語言處理與機器學習模型，能深入理解詐騙文字的語意，辨識隱晦或誘導式內容，提升文字辨識的準確性。同時，優化後的圖像識別模型在處理低畫質、背景複雜或非標準化設計的圖片時，依然能維持穩定且高效的辨識效果。為了應對新型詐騙手法，模型訓練納入動態更新的多樣化數據，確保即時學習並適應最新詐騙特徵，克服數據不足的侷限。此外，透過多形式內容的整合分析，能跨越單一模態限制，有效關聯並識別多樣化詐騙特徵。利用 AI 技術提供全面且高效的詐騙內容辨識方案，協助民眾快速識別潛在風險，降低受騙機率，並因應日益複雜的詐騙手法。

文獻探討與回顧

根據本研究議題，下列將針對光學影像辨識、文字探勘技術、語言訓練模型進行相關議題的探討。

一、光學影像辨識(Optical Character Recognition: OCR)

在此研究中，選擇合適的圖片辨識技術對於提升識別精度至關重要。目前有多種圖片辨識的 OCR 技術和工具可供選擇，其中包括 Microsoft 的 Azure OCR 和開源工具如 Paddle OCR。這些工具在文本識別的準確度、處理速度及支持語言等方面都具有差異。因此，以下將對比這些主要 OCR 工具，分析其在識別詐騙圖片中的表現，並從多個方面進行評估，包括：識別準確性、處理速度、流量限制、對不同語言（特別是繁體中文）的支持等。

Tesseract OCR 是由 Google 維護的開源 OCR 庫，廣泛應用於文本圖像識別，支持多語言並具有良好的精度。然而，其在處理複雜背景圖像時效果較差，且無法直接處理多頁 PDF 文檔。根據 Montesinos and Cárdenas (2024) 的研究中使用 Tesseract 對固定位置之文字進行辨識，平均準確率卻僅有 82.8%，標準差也高達 10.746，顯示其不管在精準度不高且數據波動較大，而在 Li (2024) 的研究中對於較為複雜的背景及不同的前後處理方式下，Tesseract 的準確率則是難以突破 60%。相比之下，PaddleOCR 基於深度學習技術，具有高識別精度，特別是在背景複雜的圖像中表現出色，並支持多語言。但其對硬體有一定要求，使用者可能需要對模型進行訓練與調優，技術門檻較高。在 Cavalcante et al. (2024) 中同樣進行對固定位置進行文字的辨識，其準確率則是高達 98.31%，Zhang et al. (2024) 則是對廣告中的圖片進行識別，在環境較為複雜的情況下，仍然能有 93.17% 的準確率，足見其穩定性。Azure OCR 作為 Microsoft Azure Cognitive Services 提供的雲端服務，利用深度學習模型進行高精準度的文本提取，能夠高效處理複雜的圖片和文件。其雖然速度快且精度高，但作為一項雲端服務，免費使用流量有限且不開源。在 Bardvall and Hassle (2024) 對於種類較多、內容較複雜的發票進行識別，仍然能有 94.33% 的高準確率，缺點則是因其不開源，無法透過調整相關參數進一步提升準確率。

表 1、圖片辨識工具優缺點比較

工具	優點	缺點
Tesseract	開源免費，多語言支持，可擴展語言包	對於複雜背景的圖像效果較差，不支持直接處理多頁 PDF 文檔
Paddle	高準確度，特別是處理複雜背景的圖片，處理速度快	對硬體有一定要求，需要技術知識進行模型訓練及調優
Azure	高精度處理複雜圖片與文件，雲端處理速度快	免費流量有限，不開源，無法調整相關參數

表 2、相關 OCR 的比較分析

Experiment	Method	Accuracy	Precision	F1	CER
Raw without Autocorrec	Tesseract	57.73	51.62	63.95	0.11
	Paddle	72.93	70.46	76.98	0.06
	Azure	75.25	79.83	77.89	0.04
	Integrated Method	79.33	79.83	82.25	0.02
Raw with Autocorrect	Tesseract	58.21	52.58	64.69	0.11
	Paddle	73.43	71.92	77.84	0.06
	Azure	75.88	80.05	78.44	0.04
	Integrated Method	79.33	80.05	82.37	0.02
Thresholding with Autocorrect	Tesseract	60.38	55.81	67.7	0.09
	Paddle	75.68	71.82	77.97	0.05
	Azure	78.21	80.93	80.27	0.03

	Integrated Method	80.28	81.06	83.42	0.01
--	-------------------	-------	-------	-------	------

資料來源：Li (2024)

根據表 2 的研究數據顯示 Li (2024)，在不同處理方法下，不同 OCR 引擎的各項數據，包含 Accuracy (準確率)、Precision (精確率)、F1(精確度與召回率的調和平均數)、CER (字符錯誤率)。在 OCR 辨識中，不同的處理方式對結果有顯著影響。在未進行後處理或自動修正的情況下，Azure 和 Integrated Method 的表現略優於 Paddle，而 Tesseract 則相差較多。而在加入自動修正後，各方法的準確性和穩定性均有所提升，儘管排名順序不變，可見自動修正對減少辨識錯誤的助益。此外，應用 Thresholding 技術進行前處理（如將灰度圖像轉為黑白以簡化結構）後，各方法的表現進一步提高，再次強調了前處理與後處理在提升 OCR 辨識準確性中的重要性。

由上方數據可得知，雖然 PaddleOCR 在不管是準確度還是錯誤率等評估指標上皆略輸 AzureOCR 一籌，但是在數據相差不大的情況下，其較快的處理速度及可自行對模型進行訓練及調優的優勢，使得其相較於 AzureOCR 有較大的提升及優化空間，因此本研究將選擇 PaddleOCR 為圖片辨識所使用的 OCR 方法。

在表 2 中，在同樣進行 Autocorrect 處理後，加上 Thresholding 技術可以使得各個 OCR 模型的準確度都進一步提升。由於常見的 Autocorrect 功能大多數僅支援英文，如 Li (2024)中使用 Python 內建的檢查方法，而中文的校正模型相對更為複雜，且可能顯著影響處理速度，因此在整體的即時性及友善性的考量下，本研究不進行 Autocorrect 處理，而是專注於利用 Thresholding 技術來提高辨識準確度。Otsu's Thresholding 是一種自動化的影像預處理技術，主要用來將灰度圖像轉換為二值圖像。這種方法假設圖像的灰度分佈有兩個峰，分別代表前景和背景，透過找到能最大化兩者差異的閾值，來清楚地分割前景和背景。在實際應用中，此方法被廣泛應用於 OCR 技術，尤其是在處理具有不同光照和對比度的圖像時，能夠提供更清晰的文本與背景的區分。通過使用 OpenCV 庫，此方法能夠自動計算最佳閾值，將灰度圖像轉換為二值圖像，而無需手動設置閾值，這使其在面對不同的文檔條件（如光線變化或對比度不均）時具有高度的適應性，從而增強了 OCR 技術對文本的識別能力。

另外表 2 所提到的 Integrated Method，旨在通過結合多個 OCR 的輸出來提高圖像中文字識別的準確性和可靠性。圖像將被四個不同的 OCR 同時處理：Tesseract、Keras、Paddle 和 Azure OCR。這些來自不同 OCR 的輸出結果會被匯總並傳送至綜合評分系統，在這裡系統會根據每個 OCR 提供的置信度和 CER 對每個單詞進行評估。若某個 OCR 引擎在特定類型的文本中表現穩定且可靠，那麼在評分過程中，它的輸出結果將會被賦予更高的權重。最終，通過結合這些結果，系統會選擇出具有最高評分的單詞，並將這些單詞組合成最準確的文本版本，從而提供對圖像中識別文字的最佳結果。雖然 Integrated Method 能顯著提高識別準確度，但此系統需要同時運行多個 OCR 引擎，這會消耗大量的計算資源和時間。特別是當處理大量圖像或高複雜度的內容時，系統的運行效

率可能會大幅下降。此外，欲整合來自不同 OCR 的輸出，也需透過複雜的算法在不同情況下對每個 OCR 的結果進行加權，如何設計及高效運行此系統的是一大問題，因此本研究難以採用此技術。

二、文字探勘技術

網路爬蟲工具 **Puppeteer** 是由 Google 開發的 Node.js 函式庫，提供多種 API 用於控制和模擬 Chrome 或 Chromium 瀏覽器。在本研究中，Puppeteer 被選為主要的網路爬蟲工具，理由在於其在 JavaScript 生態中的廣泛應用與高效能。根據 2021 年的統計數據，Puppeteer 的每週下載量達到 220 萬次，證明其在開發者社群中的受歡迎程度與實用性(Färholt, 2021)。

Garcia et al. (2024)對於多種自動化工具做出比較，其中 Selenium 是一個成熟且完全基於標準的瀏覽器自動化工具，提供跨瀏覽器和多語言支援，但其本質是一個通用瀏覽器自動化庫，而非測試框架，因此缺乏內建的測試功能，例如自動等待、視覺化測試或控制台日誌收集。相比之下，Cypress 利用 JavaScript 與被測應用程式同時運行，透過自動等待和快速執行提供良好的測試效能，但由於其依賴 JavaScript，對某些操作存在限制；Playwright 則提供完整的端到端測試框架功能，但其依賴修補過的瀏覽器版本進行自動化，可能與用戶實際使用的瀏覽器版本存在偏差。而 Puppeteer 是一個專注於高效能的瀏覽器自動化工具，其透過直接使用 Chromium DevTools Protocol (CDP) 與瀏覽器通信，實現了全面的功能，包括精確控制、控制台日誌收集和複雜的用戶行為模擬，其功能主要集中於基於 Chromium 的瀏覽器。此外，隨著 W3C WebDriver BiDi 協議，也就是綜合了過往協議的優點的全新自動化標準的發展，Puppeteer 已經搶先整合了初步支援，使得其功能將更加強大。

在本研究中，Puppeteer 被用來模擬人類的瀏覽器操作，例如打開網頁、提取文字和圖片資訊，從而實現對目標網頁中文字與圖片等相關資訊的爬取，以供進一步的辨識與分析使用。

三、訓練模型

詐騙辨識模型主要使用 TF-IDF 和 BERT 這兩種技術。TF-IDF (Term Frequency-Inverse Document Frequency) 是一種統計方法，用於評估單詞在文件集合或詞庫中的重要性，廣泛應用於資訊檢索和文字探勘。BERT (Bidirectional Encoder Representations from Transformers) 則是一種基於 Transformer 架構的預訓練語言模型，具備雙向編碼能力，能同時考慮單詞左側與右側的語境。在大規模無標註文本數據上完成預訓練後，BERT 通過微調可有效應用於特定任務，展現出卓越的遷移學習能力。Sun et al. (2022)的研究中，如表 3 所示，BERT 相較於其他模型(如: LSTM、CNN)，其準確率都大幅領先 20%左右，這表明 BERT 預訓練語言模型比其他模型更有效。基於 BERT 預訓練模型，加入專有名詞的特徵，並用 TF-IDF 方法調整專有名詞的重要性權重，使模型能夠獲得更多的語意訊息，同時捕捉關鍵專有名詞的訊息表示。使最終的結果充分融合關鍵字特徵，從而達到更好的實驗效果。因此在本研究之模型

中，我們結合了 TF-IDF 以及 BERT，綜合兩者的優勢，使其能對關鍵字重要性以及前後語意判斷進行綜合考量，使得詐騙辨識的準確度能夠更加精準。

表 3、不同模型試驗結果對比

Model	R(準確度)%
LSTM	65.33
CNN	66.63
BERT	90.87
BERT+TF-IDF	92.55

資料來源：Sun et al. (2022)

另外 Zhang et al. (2024)中使用了 CLIP 模型用於文本及圖像的比對，進一步增強的辨識能力。CLIP 模型在辨識方面展現了傳統深度學習模型不具備的優勢，省去了標記資料的複雜以及侷限性。首先，CLIP 模型採用了結合圖像與文本數據的學習方法，透過對比學習來區分不同的數據樣本。

為了進一步提升 CLIP 的辨識能力，此研究採用了 Tip-Adapter 技術進行輕量化微調。Tip-Adapter 是透過引入緩存模型（Cache Model），將預計算的數據特徵與 CLIP 模型的輸出結合，無需調整 CLIP 本身的權重，便能實現對特定任務的快速適應。這不僅保留了 CLIP 模型的零樣本學習能力，還提升了模型在特定任務上的準確性與效率。通過此技術，不僅增強了模型對於多樣化圖片形式的適應性，包括全新或未見過的圖片，還使模型能夠理解並推理不同類別圖片的特徵與意圖。此外，微調後的 CLIP 模型展現了強大的零樣本學習能力，不需要大量標註數據即可辨識圖片。如圖二所示，該方法將圖片文本標籤轉為圖片，構建文本-圖片的比對，然後通過模型獲取文本與圖片對的相似性分數，生成零樣本預測結果，這有效解決了實際應用中數據稀缺或新類別識別的問題。得益於多語言訓練數據，CLIP 模型還具備跨語言理解能力，可處理多語言文本數據，實現跨語言的圖片辨識。

因此若將 CLIP 引入現有的詐騙辨識模型，能顯著提升對圖像和文字結合的詐騙辨識能力。本研究使用 PaddleOCR 及網路爬蟲提取網頁中的圖片及文字，結合 BERT 和 TF-IDF 進行文字內容的詐騙判斷，而 CLIP 則可以檢測圖像與文字之間的語義一致性，例如判斷詐騙廣告中文字與圖片是否匹配，減少因圖文不符而影響檢測結果的情況，還能分析純圖片中的視覺符號（如二維碼、Logo）來提取更多潛在線索。此外，CLIP 的零樣本學習能力讓模型能處理未見過的新型詐騙樣本。因此 CLIP 的引入不僅能補足現有模型在圖像語義分析上的弱點，還能提高檢測準確性，增強模型對新型詐騙的適應力和辨識能力。

2. Create dataset classifier from label text




圖 2、CLIP 零樣本學習圖

資料來源：OpenAI (2024)

研究方法與步驟

一、研究方法

為了應對多樣化的詐騙手法，本研究採用模擬的方法，透過蒐集各項數據及 Open Data，結合網頁爬蟲、OCR 及機器學習技術，模擬分析並訓練出一套能有效辨識詐騙內容的模型。首先，透過網頁爬蟲技術自動蒐集欲辨識網站中的文字與圖片資料，建立多樣化的研究數據集。接著，運用 OCR 技術處理圖片，提取其中的文字內容，並結合適當的處理以提升辨識的準確度。隨後，整合爬取的文字與 OCR 生成的文本信息，進行語意比對與篩選。最終，通過 TF-IDF 和 BERT 模型進行特徵提取與分類分析，辨識內容是否涉及詐騙行為。這種多層次的方法旨在應對日益多樣化且複雜的詐騙手段，提高檢測的準確性與可靠性。

二、研究步驟

步驟一、目標網站選擇與確認

確定研究所需的目標網站，針對不同類型的詐騙案例範疇（如購物詐騙、投資詐騙等）選取相關網站，其中包括一般正常的新聞網站、購物網站，以及政府所公布的詐騙網站等，並進行網站結構和數據特性分析。在確保合法合規的前提下，確保能夠獲得有效的數據。

步驟二、獲取網站資料

使用爬蟲工具 Puppeteer 設計自動化的爬蟲程式來抓取網站上的文字和圖片網址，利用爬蟲技術對確定的目標網站進行數據蒐集，提取網站中的文字內容及圖片 URL，作為後續分析的基礎。

步驟三、圖片預處理

抓取到圖片的 URL 之後，會下載圖片並轉換為 OpenCV 格式以便進行後續處理。在這個過程中，會檢查圖片的有效性，並確保圖片能夠成功下載和解碼。

接著，針對下載完成之圖片進行影像前處理實驗。本研究不僅採用 Otsu 閾值法進行二值化，亦額外比較多種常見影像處理方法，包括影像放大（300 DPI）、NLM 去噪、反銳化、直方圖均衡化、CLAHE 與 Gamma 校正。各方法皆獨立套用於相同圖片資料集，以確保比較之公平性，並作為後續 OCR 效能評估之依據。

步驟四、圖片辨識

接著，使用 Paddle OCR 對圖片進行文字識別，將圖片中的文字轉換為文本數據。在這個過程中，我們會對 OCR 輸出的結果進行校正與優化，這可能包括語言模型的調整或拼寫錯誤的自動更正，以提高最終文本的準確度。

步驟五、CLIP 模型模擬分析

對於經過 OCR 處理過的圖片文字及爬蟲所獲得的原始文本數據，我們將結合兩者並應用 CLIP 模型進行分析。CLIP 模型能夠將圖片與文字數據進行聯繫，通過學習將圖片中的語意與爬蟲抓取的文字進行比對和匹配。這樣，我們可以確保圖片和文本在語義上的一致性，並篩選掉那些無關或語意不符的文字。透過 CLIP 模型，我們能夠進一步提高資料的準確性，篩選出更多具有詐騙可能的內容。此外，CLIP 模型所具備零樣本學習能力，能夠在無需特定訓練樣本的情況下，自動識別和分類新的圖片與文字配對，進一步提升模型在處理未知詐騙模式方面的準確性。

為評估 CLIP 在整體 OCR 強化流程中的實際效益，本研究將設計不同處理流程組合進行比較。比較組合包含：僅使用原始 OCR 輸出、不經影像處理之 CLIP refinement；僅進行影像前處理後之 OCR；以及結合影像前處理與 CLIP refinement 之完整流程。透過比較不同組合下的 OCR 辨識結果，可分析影像層級強化與語義層級精煉是否具有互補效果，並評估其對後續詐騙辨識模型之影響。

步驟六、詐騙辨識

我們使用 TF-IDF 模型提取每篇文本的特徵，這有助於識別文本中的關鍵詞，並衡量每個詞在語料庫中的重要性。隨後，我們運用 BERT 模型進行語意分析，以此理解語境中的語言特徵並進行詐騙識別。BERT 模型將幫助我們識別文本中的詐騙內容，這可能是一些特定的詐騙語言或警告標語。並且通過結合兩者綜合判斷其是否與詐騙行為相關，最終將結果標註為「詐騙」或「非詐騙」並輸出此數據為詐騙的機率。

步驟七、結果驗證

首先，我們將根據實際圖片對圖片辨識的結果進行比對，確保其準確性。如果發現辨識結果與實際情況存在較大偏差，我們將調整預處理方法或辨識參數，以進一步提升識別效果。

對於最終辨識結果，我們會選擇一些已知的詐騙和非詐騙範例作為測試資料，並將這些資料的預測結果與實際情況進行對比，檢視模型能準確區分詐騙和非詐騙且給予合適的詐騙準確度。本研究依不同階段任務性質採用對應之評估指標。於影像前處理與 CLIP 比較階段，使用 CER、Accuracy、Precision、Recall 與 F1-score 評估文字辨識品質；於最終詐騙辨識階段，則以 Accuracy、AUC-ROC 與 Average Precision 衡量模型之分類與排序能力。

最終，根據測試結果及評估指標，我們會優化整體辨識流程，確保它能夠在各種情況下皆能有效地識別詐騙內容。

步驟八、整理研究結果

對於各個步驟的效能數據及整體的準確度進行紀錄及分析，並匯總目前還未能改善的問題，作為後續研究及改進的依據。

研究結果

一、影像前處理

在本研究進入 OCR 辨識、CLIP 語意比對以及 BERT 詐騙判斷之前，首先必須確保輸入模型的圖片具有良好的可辨識性。因此，第一階段的目標是評估各種常見的影像前處理方法，找出最適合作為後續 OCR 前置處理的技術，以提升整體詐騙辨識的穩定度與準確性。

本研究所使用的圖片資料均來源於公開網站《mygopen》整理的詐騙案例。該網站長期揭露假訊息與詐騙內容，其圖片屬於可公開存取之資訊。研究過程中僅以非商業、教學研究目的進行分析，不涉及再散布與營利用途，因此符合著作權合理使用範圍。資料皆由手動下載圖片再作人工標註，確保研究資料來源明確、合法。

為全面評估影像前處理對 OCR 辨識效能之影響，除了 Otsu 閾值法之外，本研究亦於此階段比較多種類型之影像處理策略。比較方法可概分為三類：第一類為解析度與幾何調整方法（影像放大），用以改善文字可視性；第二類為雜訊抑制方法（NLM 去噪），以降低背景干擾並保留文字結構；第三類為影像強化與對比調整方法（反銳化、直方圖均衡化、CLAHE 與 Gamma 校正），旨在提升文字與背景之對比程度。所有方法皆對同一組圖片執行處理後以 PaddleOCR 進行辨識，並以 CER、Accuracy、Precision、Recall、F1 Score 作為評估指標。

表 4、各影像前處理方法之 OCR 效能比較

前處理方法	CER	Accuracy	Precision	Recall	F1 Score
原始	0.2528	0.7560	0.8405	0.8394	0.8381
放大 300 DPI	0.3374	0.6988	0.7761	0.8295	0.7966
去噪 NLM	0.2469	0.7712	0.8502	0.8701	0.8593
反銳化	0.2605	0.7412	0.8089	0.8228	0.8147
直方圖均衡化	0.2875	0.7342	0.8094	0.8645	0.8355
CLAHE	0.2640	0.7302	0.8006	0.8137	0.8063
Gamma 校正	0.2486	0.7459	0.8139	0.8215	0.8170
Otsu 閾值	0.2518	0.7425	0.8150	0.8275	0.8198

由表 4 可見，多數影像增強類方法（例如：直方圖均衡、CLAHE、反銳化）雖然在一般影像處理中具有提升文字清晰度的效果，但在詐騙截圖或廣告情境中反而表現不佳；同時，過度提升的對比也會使干擾訊號更為明顯，進一步降低 OCR 辨識穩定度，可見增強類方法整體多無法改善 OCR 效能。

相較於其他影像增強與轉換方法，本研究所採用的 NLM 去噪在整體評估指標上呈現正向效果。在表 4 中，NLM 取得最低 CER (0.2469) 與最高 F1 分數 (0.8593)。NLM 的優勢在於其「非區域性比對」特性，能有效平滑背景噪聲，同時保留文字邊緣結構，使細節要求較高的漢字辨識受益最大。因此，此方法非常適合應對詐騙截圖中常見的雜訊問題。

而本研究原計畫書中即規劃採用的 Otsu 閾值法，在測試中呈現高度穩定的特性。雖然其改善幅度不如 NLM，但 CER 與 F1 分數皆維持接近原始影像的水準，且在跨亮度、對比度、背景複雜度等多種情境下皆無出現大幅惡化。這顯示 Otsu 方法不僅具有一定的泛用性，也能作為安全且可靠的前處理程序。

基於上述分析，本研究最終採取以下決策方向：

1. NLM 去噪：
其在多項評估指標中表現最佳，能有效提升 OCR 輸入品質，是本研究的首選影像前處理策略。
2. 保留 Otsu 閾值法作為標準二值化流程：
其穩定性高、不易破壞文字資訊，可確保即使遇到不同來源條件的圖片，仍維持一致的辨識結果。
3. 不採用 300 DPI 放大、直方圖均衡化、CLAHE、反銳化等方法：
這些方法在詐騙截圖情境中提升有限，甚至造成辨識惡化，不符本研究需求。

本階段結果使本研究得以建立「NLM 去噪 + Otsu 閾值」之標準影像前處理流程，完整提升後續 CLIP 語意比對、詐騙辨識的整體資料品質，有助於提高整體詐騙辨識系統之可靠性。

二、CLIP 方法與比較

本研究在完成影像前處理後，進一步比較多種文字辨識流程，以評估不同方法對 OCR 準確率的影響。整體流程涵蓋三類方法：未經任何前處理的原始 OCR、影像前處理（NLM 去噪與 Otsu 閾值化）、CLIP refinement。實驗包含上述方法的組合，最終比較其 CER、Accuracy、Precision、Recall 與 F1 指標。

在 CLIP 的應用部分，本研究作法為：首先將 OCR 模型輸出的每一個行級結果裁切成行級影像，接著使用 CLIP 的影像編碼器與文字編碼器分別萃取特徵，再計算影像與多組詐騙相關語義模板之間的跨模態相似度。若某一行影像與詐騙語意的不相似度過高，則視為非主要情境文字（如 UI 介面、按鈕、背景字），予以降低權重或直接剔除；反之，若行影像與詐騙模板相似度較高，則保留或提高其 OCR 信任度。此方法能在不改變影像本身的情況下，以語義資訊補足 OCR 僅能依賴字形特徵的不足。

表 5、不同組合方法之 OCR 效能比較

方法	CER	Accuracy	Precision	Recall	F1 Score
原始 OCR	0.2528	0.7560	0.8405	0.8394	0.8381
NLM 去噪 + Otsu	0.2485	0.7562	0.8353	0.8563	0.8447
CLIP refinement	0.2403	0.7777	0.8475	0.8692	0.8566
NLM + Otsu + CLIP	0.2333	0.7857	0.8513	0.8923	0.8703

由表 5 可知，經過不同前處理與 CLIP 精煉策略後，各方法在字元錯誤率（CER）與整體文字辨識品質上呈現逐步改善的趨勢。單純使用 NLM 去噪與 Otsu 閾值化能夠稍微降低 CER 並提升 Recall，顯示去噪與二值化有助於恢復文字結構，增加被 OCR 正確識別之可能性；純 CLIP refinement 在不改變影像的前提下，透過語義過濾提高了 Accuracy 與 F1，說明語義層面的行級剪裁或保留可以有效剔除錯誤行並提升整體判斷。綜合兩類方法（NLM+Otsu+CLIP）的組合在所有指標上均達到最佳，尤其在 Recall 與 F1 上的提升最為顯著，表示結合圖像層級的訊號強化與語義層級的過濾可產生互補效果：前者改善字形可讀性，後者透過語義判斷保留關鍵行、捨棄無關或誤檢內容，進而同時提高召回與精確性，使最終文字輸出更接近 ground truth。

綜整本次實驗的結果，可以發現不同方法在 OCR 表現上呈現明顯差異，且其改善源頭可歸納為純影像增強、語義精煉與兩者互補三個面向。首先，在進行 NLM 去噪與 Otsu 閾值化後，字元輪廓的模糊度明顯降低，使筆畫結構更加清晰，因此 CER 與 Recall 均有小幅下降，顯示影像層級的處理確實能穩定提升 OCR 的低階辨識能力。然而，由於此類方法僅改善像素品質，並未具備語義判斷能力，因此 Precision 的變化相對有限，無法辨識哪些行文字真正具有語意價值。

相較之下，CLIP refinement 帶來的是語義層面的補強，其效果遠大於傳

統影像處理。OCR 本質上無法理解一行文字是否屬於「詐騙語境」，但 CLIP 能透過跨模態相似度評估該行文字與詐騙情境的語意一致性，進而篩除不具有語義重要性的行。因此在加入 CLIP 後，不僅 Recall 與 F1 明顯提升，Precision 與 Accuracy 也同步改善，反映 CLIP 能有效濾除錯誤或與任務無關的文字輸出。

更重要的是，當影像清理與語義精煉結合時，兩者展現出互補特性。NLM/Otsu 提供更乾淨、更具辨識度的影像，使初步 OCR 結果更可靠；CLIP 隨後再從語義層面做行級篩選，剔除低相關文字。這樣的雙層式架構同時降低錯誤字形與錯誤語義，使五項指標皆達到最佳表現，尤其是 Recall 與 F1 的提升最為明顯，顯示模型能在避免雜訊的前提下完整保留關鍵訊息。整體而言，本研究證實影像層與語義層的結合比單一方法具有更強的實際效益，能有效提升詐騙截圖 OCR 的整體辨識品質。

總結而言，單純的影像層處理與語義層過濾各自能帶來有限改善，但當兩者結合後，OCR 系統得以同時在低階訊號品質與高階語意一致性上得到補強，最終生成最符合人類閱讀與實際應用的文字輸出。

三、OCR 強化對詐騙辨識模型效能之影響

為評估整合影像強化後之 OCR 對詐騙辨識模型整體效能的影響，本研究在固定模型（BERT）與資料集條件下，分別比較原始 OCR 與強化後 OCR 之分類表現。評估指標包含整體分類準確度，以及能反映模型排序與判斷能力之 AUC-ROC 與 Average Precision，藉此分析 OCR 強化是否能提升模型在不同決策條件下的辨識穩定性。

表 6、OCR 強化前後於詐騙辨識模型之效能比較

方法	Accuracy	AUC-ROC	Average Precision	Prediction Confidence	F1 Score
原始 OCR	0.9200	0.8730	0.9420	0.8666	0.9474
Enhanced OCR	0.9200	0.9286	0.9713	0.8722	0.9474

表 6 比較了原始 OCR 與整合影像強化方法後之 OCR，在相同 BERT 詐騙辨識模型下的分類效能。結果顯示，在 Accuracy 以及 F1-score 指標上，兩種方法皆達到相同表現，其中 Accuracy 均為 0.92，顯示模型在兩種 OCR 輸入條件下皆能正確辨識大多數樣本。

此結果顯示，在固定分類閾值下，原始 OCR 所提供的文字資訊已足以支撐模型進行正確分類，因此單點分類指標未出現明顯差異。然而，當進一步觀察整體排序能力相關指標時，可發現經過影像強化後的 OCR 輸入，能有效提升模型在不同 decision threshold 下的整體辨識能力。

具體而言，AUC-ROC 由 0.873 提升至 0.9286，提升幅度達 6.36%，顯示模型在區分詐騙與非詐騙文本時，其整體可分性顯著改善。此外，Average Precision (AP) 亦由 0.942 提升至 0.9713，代表在高召回率條件下，模型仍能維持較高的精確度，顯示 OCR 強化有助於減少語意雜訊對分類排序的影響。

除整體分類效能外，本研究亦比較模型輸出之平均預測信心，以觀察 OCR 強化是否影響模型判斷的一致性。結果顯示 Enhanced OCR 的平均預測信心略高於 Original OCR，顯示在分類結果不變的情況下，模型對其預測結果具有較一致且集中的信心分佈。說明 OCR 強化有助於降低文字雜訊對模型判斷造成的干擾，使模型在進行詐騙辨識時能建立更穩定的判斷依據。

整體而言，雖然在單一閾值下的分類準確率未發生變化，但整體排序與判斷能力指標明確顯示，整合影像強化後的 OCR 能使模型在更廣泛的決策範圍內表現得更加穩定且可靠。




圖 3、模型性能指標比較圖

圖 3 顯示原始 OCR 與 Enhanced OCR 在多項評估指標下的比較結果。

首先，在 ROC 曲線中可觀察到，Enhanced OCR 的曲線整體向左上方偏移，其 AUC 明顯高於原始 OCR，表示在不同 false positive rate 條件下，模型能更早取得較高的 true positive rate，顯示其整體區辨能力明顯提升。

Precision-Recall 曲線亦呈現相似趨勢。在中高 Recall 區間，Enhanced OCR 能維持較高的 Precision，顯示模型在試圖捕捉更多詐騙樣本時，不易引入過多誤判。這對於詐騙偵測情境尤為重要，因為實務應用中通常傾向優先提

高召回率，以避免漏判詐騙。

由於模型輸出為詐騙機率，本研究進一步觀察在不同 decision threshold 設定下，模型 F1 score 的變化情形，以分析分類表現於不同決策條件下的穩定性。在 F1-score 與 decision threshold 的關係圖中，可以觀察到兩者的最佳 F1 值相同，但 Enhanced OCR 對應的最佳 threshold 明顯較低，代表模型在較低的預測門檻下即可達到最佳平衡狀態，顯示其對詐騙語意的辨識更為集中且明確。

最後，預測信心分佈圖顯示，Enhanced OCR 的預測結果略為向高信心區間集中，顯示在不改變最終分類結果的情況下，模型對其判斷結果具有更一致的信心分佈，進一步反映 OCR 強化後所輸入之文本品質較為穩定。

結論

一、OCR 與詐騙辨識

本研究針對近年常見以圖片或截圖形式呈現之詐騙內容，提出一套結合影像強化、OCR 與語言模型之整合式詐騙辨識流程。研究首先比較多種常見影像前處理方法對 OCR 表現的影響，並證實單純的影像增強方法在詐騙截圖情境中效果有限，甚至可能因過度強化而降低文字辨識穩定性。相較之下，降噪與穩定化導向的方法能更有效提升 OCR 輸入品質，並在多樣化詐騙圖片條件下維持較一致的辨識表現。

在影像處理層面，本研究透過實驗確認 NLM 去噪與 Otsu 閾值化能在多數詐騙圖片條件下維持穩定表現，並進一步結合 CLIP 進行語意精煉，以跨模態方式篩除非關鍵或低語意相關之文字輸出。此雙層式設計同時改善文字可讀性與語意一致性，使最終 OCR 結果更貼近實際詐騙語境需求。實驗結果顯示，OCR 強化所帶來的效益並非源自單一影像處理技術的疊加，而是來自影像層與語義層之間的互補關係：影像層處理主要穩定字形輪廓並抑制背景雜訊，使 OCR 輸出在字元層級上更為一致；語義層的 CLIP 精煉則從跨模態角度評估文字內容與詐騙語境的相關性，降低介面文字、背景資訊或誤判行對後續模型的干擾。當兩者結合時，影像層提供穩定的字形輸入基礎，語義層進一步聚焦任務相關訊號，使語言模型能更有效地學習並判斷詐騙語意。

此結果說明，對於詐騙截圖等高雜訊影像文字任務而言，單純依賴更複雜的分類模型未必能有效提升整體表現；相反地，透過跨層級的前處理設計，先行降低無關訊號與語意雜訊，反而能在不增加模型複雜度的情況下，提升模型對詐騙語意的可分性與判斷穩定性。此一觀點可作為後續詐騙辨識研究在模型設計與資料處理策略上的重要參考方向。

在詐騙辨識階段，本研究將原始 OCR 與整合影像強化後之 Enhanced OCR 分別輸入至相同之 BERT 分類模型進行比較。實驗結果顯示，在固定分類閾值設

定下，兩者於最終分類結果上呈現相近表現；然而，Enhanced OCR 能使模型在 AUC-ROC 與 Average Precision 等整體評估指標上顯著提升，並使預測信心分佈更為集中，顯示模型在不同決策條件下具有更穩定且一致的判斷行為。

進一步分析可知，OCR 強化主要體現在模型對樣本之相對排序結構與整體可分性的改善，而非必然反映於單一 decision threshold 下的分類結果。當文字輸入中的影像雜訊與語意干擾被有效降低後，詐騙與非詐騙文本在預測分數空間中的分佈趨於分離，使模型能在更廣泛的決策條件下維持良好的區辨能力。換言之，語言模型得以更專注於與詐騙語境相關的關鍵訊號，進而提升其對樣本之相對風險排序能力。此結果顯示，透過改善 OCR 輸入品質，即可在不調整核心分類模型的情況下，提升詐騙辨識系統整體判斷行為的穩定性與可靠性。

二、實務應用

在實務應用層面，本研究結果對於詐騙防制相關單位（如警政署、金融機構或事實查核平台）具有直接參考價值。由於實務系統往往需依據不同應用需求動態調整判斷門檻，例如在風險預警或大規模篩查情境中，模型是否能在廣泛的 decision threshold 範圍內維持良好區辨能力，往往比單一門檻下的分類結果更具參考價值。

本研究證實，透過導入「影像前處理結合語義精煉」的 OCR 強化流程，即可在不更動既有分類模型架構的前提下，提升模型在不同決策條件下的穩定性與可靠性。特別適用於處理社群平台截圖、廣告圖片或對話紀錄之影像文字內容。此作法不僅能降低誤判風險，亦可協助系統在高召回率需求下，維持合理的精確度，進而提升詐騙預警與通報機制之實用性。

綜合而言，本研究所提出之整合式詐騙辨識流程，透過影像層與語義層的協同設計，有效降低語意雜訊，並改善模型對樣本空間的整體判斷結構。此方法能提升詐騙截圖情境下的文字輸入品質，進而增強後續語言模型於詐騙辨識任務中的實用性與可擴展性。可進一步應用於詐騙偵測系統，或結合更多跨模態資訊，以因應不斷演進之詐騙手法。

參考文獻

1. Montesinos, C. A. L., & Cárdenas, E. J. E. (2024). Verification of Peruvian Identity Document Fraud Through OCR, Hash Algorithm, and Simulated Blockchain Database. In *Knowledge Management and Artificial Intelligence for Growth: Cases from Emerging and Developed Economies*. Cham: Springer Nature Switzerland, 165-188.

2. Zhang, H., Ding, Z., Sharid Kayes Dipu, M., Lv, P., Huang, Y., Abdullahi, H. S., Song, Z., Zhang, A., & Wang, Y. (2024). Identification of illegal outdoor advertisements based on CLIP fine-tuning and OCR technology. *IEEE Access*.
3. Cavalcante, W., Torné, I., Camelo, L., Fernandes, R., Printes, A., & Bragança, H. (2024). An ID Badge Information Extractor based on Object Detection and Optical Character Recognition. *IEEE Access*.
4. Li, Y. (2024). Synergizing Optical Character Recognition: A Comparative Analysis and Integration of Tesseract, Keras, Paddle, and Azure OCR (Doctoral dissertation, University of Sydney).
5. Bardvall, M., & Hassle, I. (2024). Automating Invoice Recognition: A Comparative Study of Large Language Models and OCR/ML Technologies.
6. OpenAI. (2024). CLIP: Connecting text and images, retrieving from <https://openai.com/index/clip/>.
7. Färholt, F. (2021). Less Detectable Web Scraping Techniques.
8. García, B., del Alamo, J. M., Leotta, M., & Ricca, F. (2024). Exploring Browser Automation: A Comparative Study of Selenium, Cypress, Puppeteer, and Playwright. In *International Conference on the Quality of Information and Communications Technology*. Cham: Springer Nature Switzerland, 142-149.
9. Sun, J. W., Bao, J. Q., & Bu, L. P. (2022, February). Text classification algorithm Based on TF-IDF and BERT. In *2022 11th International Conference of Information and Communication Technology (ICTech)*. *IEEE*, 1-4.